



DATA CARRO

Sebastián

15 de enero de 2026

Índice

1. Introducción	2
2. Conceptos	3
2.1. Machine learning	3
2.2. Random Forest	4
2.3. Métricas	5
2.4. OCR	6
2.5. Herramientas de Machine Learning con Amazon Web Service	7
3. Datos	8
4. Flujo	10
5. Despliegue e implementación	11
5.1. Gaviota	12
6. Versiones	13
6.1. RF_V_1	13
6.2. RF_V_1.5	13
6.3. RF_V_1.5 06-08-2025	13
6.4. RF_V_1.5 07-10-2025	13
6.5. RF_V_1.5 15-01-2026	14

1 Introducción

Finanzauto es una entidad financiera cuyo enfoque principal está en el financiamiento de vehículos. En este contexto, el conocimiento profundo de la dinámica del mercado automotor —particularmente del segmento de vehículos usados— es esencial para la toma de decisiones estratégicas en áreas como colocación de préstamos, evaluación de riesgo y gestión de cartera.

Una parte fundamental del modelo de negocio de Finanzauto es la venta de vehículos que ingresan a la compañía mediante procesos de dación o adjudicación. En este proceso, surge una pregunta clave con un impacto directo en los resultados financieros: **¿Cuál es el precio de venta adecuado para cada vehículo?**

Esta necesidad de contar con información precisa y oportuna sobre los valores de mercado fue el punto de partida para el desarrollo de DataCarro, una solución orientada a optimizar la gestión de activos vehiculares y fortalecer las decisiones de negocio a partir de datos.

Asignar un precio de venta a un vehículo no es una tarea trivial. Requiere un conocimiento profundo del mercado automotor, así como de todas las características específicas del vehículo en cuestión. Si bien existen especialistas en este ámbito, delegar esta tarea exclusivamente a personas presenta varios desafíos: limitaciones de tiempo, sesgos derivados de juicios subjetivos, y una baja eficiencia en contextos donde se manejan grandes volúmenes de vehículos. Gracias a los avances tecnológicos de este siglo, es posible reducir la dependencia de la experiencia humana en esta tarea. A través de la aplicación de modelos de *Machine Learning* (ML) y *Artificial Intelligence* (AI), se puede establecer un sistema que no solo automatiza y optimiza el proceso de avalúo vehicular, sino que también impone un nuevo estándar en términos de eficiencia, precisión y trazabilidad.

Este enfoque innovador da lugar a modelos de mejora continua. DataCarro combina AI y ML para actualizarse constantemente con datos del mercado automotor, lo que le permite mejorar su rendimiento con cada nueva versión. Los modelos desarrollados proporcionan información clara, estructurada y transparente, trazable en todas las etapas del proceso, y que puede ser utilizada estratégicamente para la toma de decisiones dentro de la empresa.

2 Conceptos

El desarrollo de DataCarro ha sido posible gracias a la integración de diversas tecnologías emergentes que permiten automatizar, agilizar y perfeccionar el proceso de evaluación vehicular. Para comprender cómo funciona este sistema, es necesario explorar los fundamentos técnicos que lo sustentan. En el corazón de la solución se encuentra el machine learning, que permite al modelo aprender del comportamiento histórico del mercado; en particular, se utiliza el algoritmo Random Forest, conocido por su precisión y robustez en problemas de predicción. Además, se incorpora tecnología de reconocimiento óptico de caracteres (OCR- *Optical character recognition*) para extraer información clave desde documentos físicos, lo que facilita la digitalización eficiente de los datos. Todo esto se apoya en una infraestructura sólida de bases de datos, que almacena y organiza grandes volúmenes de información, y en servicios en la nube, que garantizan escalabilidad, disponibilidad y seguridad. En las siguientes secciones, se abordarán en mayor detalle estos componentes, explicando su función, relevancia y la manera en que contribuyen a que DataCarro sea una herramienta poderosa, precisa y alineada con los objetivos estratégicos de Finanzauto.

2.1. Machine learning

El concepto de *Machine Learning* se inspira en el aprendizaje biológico; donde los seres vivos, especialmente los animales, adquieren y desarrollan habilidades, conocimientos y comportamientos a partir de sus experiencias. Un ejemplo de ello es un animal que, tras ciertas vivencias, aprende a identificar y reaccionar ante situaciones de peligro. Ese mismo concepto se puede trasladar a las computadoras, en donde estos métodos o modelos computacionales usan experiencias para mejorar su desempeño y hacer clasificaciones o predicciones más acertadas [1]. Estas experiencias en términos computacionales es la data de información pasada que se posea y que este disponible para el análisis.

En este contexto, los datos juegan un papel fundamental: constituyen la base sobre la cual se entrena el modelo. La calidad, relevancia y volumen de los datos disponibles son factores determinantes para el éxito del aprendizaje automático. Sin datos adecuados, cualquier modelo, por sofisticado que sea, corre el riesgo de fallar o de aprender patrones incorrectos. Por ello, contar con una buena base de datos es el elemento más esencial en cualquier proyecto de *Machine Learning*.

El campo del *Machine Learning* ha experimentado una expansión significativa en los últimos años, consolidándose como una herramienta clave tanto en entornos académicos como en el ámbito empresarial. Este crecimiento se debe, en gran medida, al desarrollo de una amplia variedad de modelos que responden a distintas formas de aprendizaje automático, así como al aprovechamiento de fundamentos estadísticos establecidos desde hace décadas. Entre estos modelos se encuentran desde enfoques más sencillos, como la regresión lineal, hasta algoritmos de mayor complejidad como *Random Forest* y redes neuronales, estas últimas también inspiradas en principios biológicos.

2.2. Random Forest

Dado que el *Machine Learning* tiene sus raíces en principios biológicos de aprendizaje, también es válido preguntarse qué otros elementos de la naturaleza podemos adaptar a estos modelos. De este tipo de ideas surge *Random Forest* o, en español, bosque aleatorio. Pero antes de hablar de un bosque, primero hay que entender qué es un árbol en este contexto. En los métodos de ML, un árbol hace referencia a un árbol de decisión, llamado así por su estructura ramificada, que se asemeja tanto a las raíces como a las ramas de un árbol natural. Se le llama “de decisión” porque se basa en aplicar reglas que dividen los datos en distintas regiones. En cada nodo del árbol se toma una decisión basada en alguna característica de entrada (por ejemplo, el kilometraje o el año del vehículo), y según el resultado, el dato “baja” por una de las ramas [2].

Este proceso se repite en cada nodo, dividiendo los datos en subconjuntos cada vez más homogéneos, hasta llegar a los nodos terminales o “hojas”, donde se asigna un resultado final, como una categoría o un valor numérico. Los árboles de decisión son modelos muy intuitivos y fáciles de interpretar, aunque tienden a sobre-ajustarse si se usan de manera individual. De ahí surge la idea del bosque aleatorio, donde se combinan muchos árboles para lograr predicciones más robustas y estables.




Figura 1: Ejemplo de un esquema de un árbol de decisión, en el cual N_i son los nodos, X_j son los valores de ingreso, R_k las hojas finales y $\hat{y}_l$ el valor de salida de cada hoja.

Este modelo se basa bastante en valores promedios, ya que la salida de cada hoja son valores promedios, los cuales matemáticamente se pueden expresar como :

$$\hat{y}_l = \text{Average}\{y_i : x_i \in R_l\} \quad (1)$$

y al final la decisión total del bosque aleatorio es el promedio de las hojas finales de N arboles que se usen en el modelo [3, 4] .

2.3. Métricas

El modelo de *Random Forest* ha mostrado, a lo largo de los años, un gran potencial en distintas áreas, como en descubrimientos de genes importantes, la predicción de interacción de proteínas [3], la estimación de precios en el mercado de valores [5], entre otras. Esto debido a su buen rendimiento en las predicciones, su robustez frente a datos ruidosos y su capacidad para modelar interacciones complejas [3].

Pero, ¿cómo se puede verificar que sea un buen modelo y que esté aprendiendo correctamente? Para ello, necesitamos alguna métrica matemática que nos indique tanto, a nosotros como al computador, que tan bien esta modelando los datos. Entre estas métricas esta el *Root Mean Square Error* (RMSE), el cual permite cuantificar la diferencia de los valores reales con los valores predecidos. Matemáticamente se expresa de la siguiente forma:

$$RMSE = \frac{1}{\sqrt{n}} \sqrt{\sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2)$$

en donde y_i , $\hat{y}_i$ son los valores predecidos y n el numero de datos.

Esta diferencia de valores proviene de una interpretación geométrica, específicamente de una distancia Euclidiana. Esta se puede definir de la siguiente forma: sean los vectores y y $\hat{y}$ que pertenecen a $\mathbb{R}^n$, entonces su diferencia se puede expresar de la siguiente manera:

$$\|y - \hat{y}\| = \sqrt{\sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3)$$

y si se normaliza esa distancia euclidiana por $1/\sqrt{n}$ obtenemos el RMSE. Esto queda más claro en la figura 2.

Ya teniendo la métrica de RMSE, es fácil calcular el error de los modelos con respecto a la media de los valores. Este error relativo se puede obtener mediante un cociente entre esos valores.

Otra métrica importante es el R^2 , llamado coeficiente de determinación, el cual evalúa qué tan bien los modelos son capaces de replicar los resultados observados. Esta métrica depende tanto de la suma de los cuadrados de los residuos como de la suma total de cuadrados, la cual es proporcional a la varianza. Estos se presentan de la siguiente forma:

$$SS_{res} = \sum_i (y_i - \hat{y}_i)^2 \quad (4)$$

$$SS_{tot} = \sum_i (y_i - \bar{y})^2 \quad (5)$$

siendo $\bar{y}$ la media de los valores de y , o de la data original




Figura 2: Diferencia euclidiana (lineas rojas), entre valores predecidos (linea azul) y valores reales (puntos verdes).

$$\bar{y} = \frac{1}{n} \quad (6)$$

con estos elementos se puede definir el R^2 como:

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} \quad (7)$$

esto significa que, entre más cercano sea el valor de R^2 a 1, mejor será el modelo. A diferencia del RMSE, donde ocurre lo contrario: mientras más cercano sea a 0, mejor será el modelo.

2.4. OCR

Así como en *Machine Learning* se busca imitar procesos de aprendizaje humanos, en otros campos de la inteligencia artificial también se han desarrollado tecnologías que replican habilidades propias de las personas. Un ejemplo de esto es el OCR, una tecnología diseñada para que las máquinas puedan “leer” texto desde imágenes o documentos escaneados, tal como lo haría una persona al ver una hoja impresa. Es decir, se le enseña al computador a reconocer letras, números y símbolos dentro de imágenes, y luego convertir esa información en texto digital editable.

Esta tecnología es clave en muchos procesos automatizados porque permite extraer información desde documentos físicos sin intervención humana. En el caso de DataCarro, el OCR cumple un papel fundamental: permite extraer datos técnicos o características de vehículos directamente desde formularios, fichas técnicas o reportes escaneados, que de otra forma tendrían que ser digitados manualmente. Al combinar OCR con modelos de *Machine Learning*, se logra un sistema más eficiente y escalable, capaz de procesar grandes volúmenes de información con rapidez y precisión.

2.5. Herramientas de Machine Learning con Amazon Web Service

En el desarrollo de DataCarro también ha sido fundamental el uso de servicios en la nube, particularmente a través de AWS (*Amazon Web Services*). Esta plataforma ofrece una variedad de herramientas que van desde almacenamiento y bases de datos hasta servicios especializados en *Machine learning* y procesamiento de lenguaje natural. Gracias a esta infraestructura, no solo es posible entrenar y ejecutar modelos complejos sin necesidad de invertir en servidores físicos, sino que también se pueden escalar los recursos fácilmente según la demanda del sistema.

Dentro de este ecosistema, utilizamos un modelo de lenguaje (LLM - *Large Language Model*) alojado en AWS para resolver una tarea específica: evaluar el nivel de daño de un vehículo a partir de una descripción textual. Los LLM son modelos de inteligencia artificial entrenados con grandes volúmenes de texto, capaces de comprender y generar lenguaje natural con un alto grado de precisión. Este tipo de integración demuestra cómo los servicios en la nube no solo facilitan la infraestructura técnica, sino que también permiten incorporar capacidades de inteligencia artificial de forma rápida y eficiente dentro del flujo del sistema.

3 Datos

Una parte clave para el desarrollo de cualquier modelo de *Machine Learning* es contar con los datos adecuados. Como se mencionó anteriormente, la calidad y la estructura de la información son esenciales para que el modelo aprenda correctamente y pueda hacer predicciones precisas. En el caso de **DataCarro**, se recopila y organiza una variedad de variables que permiten evaluar de forma integral el valor de un vehículo. A continuación, se describen las principales columnas contenidas en los archivos de entrada (CSV) utilizados para entrenar el modelo:

- **Código Fasecolda, Marca, Línea y Referencia:** estas variables permiten identificar de manera única cada vehículo en el sistema. En particular, el *Código Fasecolda* es un identificador único compuesto por ocho dígitos que se utiliza en Colombia para clasificar y valorar comercialmente los vehículos, tanto nuevos como usados. Su estructura se divide en tres partes: los tres primeros dígitos indican la marca del vehículo, los dos siguientes identifican la tipología vehicular (como automóvil, motocicleta, camión, etc.), y los últimos tres corresponden a un consecutivo que permite distinguir entre las diferentes configuraciones de una misma marca y tipo. Este sistema ha sido estandarizado por Fasecolda (Federación de Aseguradores Colombianos) y es ampliamente adoptado por aseguradoras, concesionarios y plataformas de valoración para garantizar uniformidad en la identificación de vehículos en el país. La relevancia del código Fasecolda radica en su capacidad para facilitar procesos como la suscripción de pólizas de seguro, la compraventa de vehículos y la consulta del valor comercial actual. Gracias a este código, los usuarios pueden acceder fácilmente a la Guía de Valores de Fasecolda, donde se proporciona una ficha técnica detallada de cada vehículo, incluyendo aspectos como su año modelo, valor comercial, tipo de carrocería y accesorios. Así, el código no solo agiliza trámites administrativos, sino que también proporciona una base confiable para tomar decisiones financieras informadas relacionadas con el mantenimiento, aseguramiento y negociación de vehículos en el mercado colombiano. Además, al estar expresado como un valor numérico, el código Fasecolda **facilita el procesamiento computacional de los datos**, ya que los modelos de *Machine Learning* trabajan de manera más eficiente con números que con texto libre. En otras palabras, el código actúa como una llave estructurada que resume e integra toda la información técnica del vehículo de forma precisa y estandarizada.
- **Modelo y Kilometraje:** dos variables fundamentales para estimar la depreciación del vehículo. El modelo representa el año de fabricación, y el kilometraje es uno de los factores más asociados al desgaste mecánico.
- **Fecha venta:** representa el momento en que el vehículo fue puesto en venta. Es útil para relacionar el precio con las condiciones de mercado en un punto específico del tiempo.

- **Ubicación:** hace referencia a la ciudad de matrícula o donde se encuentra el carro actualmente. Además, se construye una variable transformada llamada **Ubicación int**, donde a cada ciudad se le asigna un valor numérico entre **0 y 4**, siendo **0 Bogotá** y, por ejemplo, **4 Cartagena**. Esta codificación busca cuantificar cómo influye la región geográfica en el valor del vehículo, ya que factores como el clima, la demanda local y el nivel de desgaste por geografía pueden afectar el precio.
- **Demanda:** es una variable calculada a partir del número de registros del vehículo en el **RUNT** a lo largo del tiempo, indicando qué tanto se ha comprado ese tipo de carro en el país. Esta variable es muy útil para entender la dinámica de mercado y ajustar el precio según la popularidad del vehículo.
- **Combustible:** indica si el vehículo funciona con gasolina, diésel, eléctrico u otro tipo. Esta variable se transforma mediante one-hot encoding, una técnica que convierte cada categoría en una columna binaria (dummy), facilitando su incorporación en modelos de aprendizaje automático.
- **Descripción:** campo de texto libre donde se detallan características del vehículo. Aunque no entra directamente como variable numérica, se usa para alimentar el LLM y extraer información útil como la severidad del daño. A este se le aplica un *modelo de lenguaje (LLM)* alojado en AWS, el cual asigna una puntuación del **0 al 4** para representar el **nivel de daño del vehículo** según descripciones escritas. Este valor se convierte en una variable adicional que enriquece el análisis.
- **Gama y Gama int:** reflejan la categoría comercial del vehículo (baja, media, alta gama). Al igual que con combustible, esta variable se transforma en múltiples columnas binarias mediante *one-hot encoding* para ser entendida por el modelo.
- **Blindaje:** indica si el vehículo cuenta con protección balística.
- **Estado_vehiculo:** especifica si el carro es **nuevo** o **usado**, una de las distinciones más relevantes para determinar el precio de venta.
- **Servicio:** identifica si el vehículo tiene uso **público** o **particular**, lo cual también impacta la valoración, especialmente por temas de desgaste y condiciones operativas.
- **Estado vitrina y Estado vitrina int:** muestran si el carro se encuentra en una **venta especial** o no. Esta condición puede alterar el precio de referencia debido a promociones o contextos comerciales puntuales.
- **Pricing:** representa el **precio de venta** que se desea predecir. Es el **label** o variable objetivo utilizada para entrenar el modelo de *Random Forest Regression*, y a partir de la cual se mide la precisión de las predicciones.

Todas estas variables en conjunto ofrecen una visión 360° del vehículo y su contexto, permitiendo que el modelo capture relaciones tanto técnicas como comerciales. Contar

con esta información no solo mejora la calidad del avalúo, sino que también asegura que las predicciones estén fundamentadas en datos reales y variados, lo cual es esencial para mantener la confiabilidad del sistema.




Figura 3: Flujo del procesamiento de datos con diferentes bases de datos, para la obtención de variables extras como la gama de carros, la demanda del carro y la opinión popular del carro.

Con los datos del grupo Seissa, Asousados e históricos del grupo de analítica se corre el modelo de RM con un aproximado de 1400000 registros, los cuales se distribuyen en un 70 % para entrenamiento y un 30 % para testeo. Como resultado, el modelo obtuvo en la fase de testeo un valor de R^2 0.8332 , un RMSE de 0.32 y un error relativo de 8.3 %.

4 Flujo

La Figura 4 ilustra el flujo de procesamiento implementado por **DataCarro** para estimar el precio de un vehículo. El proceso inicia con la recolección de variables clave como la placa, el código Fasecolda, el modelo, el kilometraje, la ubicación, y otros atributos técnicos.

- El proceso inicia con la recolección de un conjunto de variables clave: **Placa, Cód-**

go Fasecolda, Modelo, Kilometraje, Ciudad de matrícula, Ubicación, Combustible, Blindaje, Estado del vehículo, Servicio, Fecha y Descripción*.

- Una vez recolectadas las variables, el sistema verifica si los **datos están completos**. Si no lo están, se emite un mensaje de error indicando que *"Faltan campos"*.
- Si los datos están completos, el sistema analiza si la variable **Descripción** se encuentra disponible. Esta variable se considera opcional (marcada con un asterisco) debido a que su ausencia no detiene el flujo del proceso: si está presente, se utiliza como entrada adicional para el modelo; si está ausente, se asume que el vehículo se encuentra en condiciones estándar.
- A partir de allí, los datos son transformados y enviados al modelo de LLM (AWS), el cual genera un valor numérico con respecto a la descripción del estado del vehículo. Este modelo ha sido entrenado para manejar tanto descripciones detalladas como suposiciones estándar.
- Finalmente, el resultado entrega el **precio estimado**, ya sea con base en la descripción o bajo condiciones estándar. En su implementación actual, el flujo automatizado tiene una tasa de éxito del **78,42 %**.

El siguiente diagrama representa el flujo de procesamiento de información para la estimación del valor comercial de un vehículo:




Figura 4: Flujo de procesamiento para predicción de precios con y sin descripción del vehículo.

5 Despliegue e implementación

El modelo ha sido implementado como un **servicio API** que permite el consumo externo mediante solicitudes HTTP. Esta arquitectura facilita su integración con siste-

mas de terceros o aplicaciones internas, promoviendo escalabilidad y reutilización (en proceso).

El servicio se encuentra actualmente **desplegado de forma local utilizando GitHub Local**, lo que permite su ejecución en entornos controlados para pruebas o despliegues en infraestructura propia. El código fuente y documentación técnica se encuentran disponibles en el siguiente repositorio:

`https://github.com/Analitica-Garaje/Datacarro\_models`

5.1. Gaviota

El primer despliegue del Algoritmo de DataCarro es para conectarlo con la herramienta de Gaviota, la cual simplemente llama a nuestro Algoritmo para hacer consultas. Para esto se disponibiliza el Algoritmo con una API, la cual cuenta con sistema de seguridad representada con un Bearer token.

6 Versiones

6.1. RF_V_1

Esta fue la primera versión la cual la documentación se basó principalmente en esta y fue lanzada en su versión de uso local en Mayo. Esta versión contaba con una variable extra que era extraída por el código y una base de Opiniones extraídas por web scraping de la página opinautos.

- Promedio estrellas: corresponde al promedio de calificaciones que el vehículo ha recibido en la plataforma opinautos.com, donde usuarios reales dejan sus valoraciones. Esta es una fuente de información subjetiva, pero valiosa, sobre la percepción del mercado.

6.2. RF_V_1.5

En esta segunda versión se elimina la variable de Promedio estrellas, esto debido a que la base de datos de ese valor no se puede actualizar constantemente y al riesgo que tiene realizar el web scraping en múltiples ocasiones, pudiendo afectar el nombre IP de la compañía.

Fecha: 17/06/2025

6.3. RF_V_1.5 06-08-2025

Métricas:

Test				Train	
R2	Relative error rmse	Relative error mac	rmse	rmse	R2
0,837	0,0865	0,0339	0,32	0,22	0,92

Cuadro 1: Performance metrics for test and train datasets

Fecha: 06/08/2025

6.4. RF_V_1.5 07-10-2025

Métricas:

Test				Train	
R2	Relative error rmse	Relative error mac	rmse	rmse	R2
0,848	0,0855	0,0337	0,33	0,22	0,92

Cuadro 2: Performance metrics for test and train datasets

6.5. RF_V_1.5 15-01-2026

Métricas:

Test				Train	
R2	Relative error rmse	Relative error mac	rmse	rmse	R2
0,9	0,0781	0,0332	0,33	0,14	0,94

Cuadro 3: Performance metrics for test and train datasets

Fecha: 07/10/2025

Referencias

- [1] Mehryar Mohri, Afshin Rostamizadeh, and Ameet Talwalkar. *Foundations of Machine Learning*. MIT Press, Cambridge, MA, 2 edition, 2018.
- [2] Andreas Lindholm, Niklas Wahlström, Fredrik Lindsten, and Thomas B Schön. *Machine learning: a first course for engineers and scientists*. Cambridge University Press, 2022.
- [3] Gilles Louppe. *Understanding random forests: From theory to practice*. PhD thesis, Universite de Liege (Belgium), 2014.
- [4] Leo Breiman, Jerome Friedman, Richard A Olshen, and Charles J Stone. *Classification and regression trees*. Routledge, 2017.
- [5] Luckyson Khaidem, Snehanstu Saha, and Sudeepa Roy Dey. Predicting the direction of stock market prices using random forest. *arXiv preprint arXiv:1605.00003*, 2016.